

3차원 가우시안 스플래팅에서 엣지 복원 향상을 위한 엣지 인지 가우시안 크기 정규화 알고리즘

Edge-Aware Gaussian Size Regularization Algorithm for Improved Boundary Reconstruction in 3D Gaussian Splatting

○서 현 규¹, 박 영 상^{2*}

¹한국기계연구원 (TEL: 010-5058-0873; E-mail: shg0873@gmail.com)

²한국기계연구원 (TEL: 042-868-7713; E-mail: pys0728k@kimm.re.kr)

Abstract 3D Gaussian Splatting(3DGS) has recently attracted attention due to its high visual quality and fast rendering speed, but, excessive gaussian expansion around edges can blur boundaries and mix adjacent structures, leading to degraded reconstruction quality. This paper investigates edge-aware strategies for improving boundary reconstruction in 3DGS. In particular, we propose two approaches: (1) an edge-aware covariance loss method, and (2) an edge-aware rendering based method. We compare three configurations under identical experimental conditions: a baseline without edge constraints, an edge-aware Gaussian size regularization method, and an edge-aware rendering-based method. The methods are evaluated in terms of Peak Signal-to-Noise Ratio (PSNR) and convergence behavior during the early stage of training. Experimental results demonstrate that the edge-aware rendering-based approach converges faster, achieving lower loss and higher PSNR within only 5 seconds of training, and ultimately improves the final PSNR by 1.09 dB over the baseline.

Keywords 3D Gaussian Splatting, Edge-aware Regularization, Gaussian Size Constraint, Scene Reconstruction

1. 서론

최근 3D Gaussian Splatting(3DGS)은 높은 시각 품질과 빠른 렌더링 속도로 주목받고 있으나, 경계(edge)가 뚜렷한 영역에서 가우시안의 크기가 과도하게 확장되면 물체 경계가 흐려지고 인접 구조가 혼합되는 문제가 발생할 수 있다. [1] 이러한 문제는 로봇 인지 성능에 영향을 줄 수 있다.

본 연구는 3DGS 기반 장면 재구성에서 경계 처리 방식에 따른 두 가지 새로운 접근 방식을 비교한다. 첫 번째는 경계 영역에서 가우시안 크기를 제한하는 공분산 손실항을 추가하는 손실함수 설계 기반 방법이며, 두 번째는 렌더링 과정에서 가우시안 크기를 직접 조절하여 경계에 반영하는 렌더 기반 방법이다. 두 방식에 따른 Peak Signal-to-Noise Ratio(PSNR) 및 학습 초기 수렴 경향을 평가하여 경계 영역 처리 방식에 따른 성능 특성을 비교한다.

2. 데이터 수집

본 연구에 사용된 데이터는 가사 도우미 로봇 환경을 모사한 실내 공간에서 수집되었으며, 데이터 수집 플랫폼으로는 로보티즈(ROBOTIS)의 AI Worker FFW-SG2 모델을 활용하였다. ZED Mini 카메라의 RGB

영상을 획득하였다. 수집된 영상에 대해 Structure from Motion(SfM) 파이프라인을 적용하여 카메라 자세를 추정하였으며 이를 3DGS 학습을 위한 입력으로 사용한다.




그림 1. AI Worker FFW-SG2(좌) 실내 가사 환경(우)

3. 방법

3.1 방법 1: Edge 영역 공분산 손실항 설계

방법 1은 기존 RGB 재구성 손실에 가우시안 공분산 손실을 추가하는 방식이다. 입력 영상에서 sobel 필터를 적용하여 수평 및 수직 방향 gradient (g_x, g_y)를 계산하고, 이를 기반으로 edge magnitude M 을 식 (1)과 같이 정의한다. 이후 정규화를 적용하여 gradient 크기가 큰 영역일수록 높은 값을 갖는 경계 가중치 W_{edge} 를 식 (2)와 같이 정의한다.

$$M = \sqrt{g_x^2 + g_y^2 + \epsilon} \quad (1)$$

$$W_{edge} = \left(\frac{M}{\max(M) + \epsilon} \right)^\gamma \quad (2)$$

다음으로 각 가우시안의 3차원 공분산을 이미지 평면으로 투영한 Σ_{2D} 를 식 (3)과 같이 정의한다.

※ 본 연구는 2026년도 산업통상자원부 및 한국산업기술기획평가원(KEIT)의 연구비 지원을 받아 수행되었습니다.(과제명 「다품종 EV 폐배터리팩의 재활용을 위한 인간-로봇 협업 해체 작업 기술 개발」, 과제고유번호: 2410017651, 과제번호 20018745).

Σ_{2D} 의 고유값은 이미지 평면에서 가우시안이 가지는 장축과 단축 방향의 분산 크기를 나타내며, 고유벡터는 해당 장축과 단축의 방향을 의미한다. 경계를 가로지르는 방향 $\mathbf{n}$ 에 대한 분산을 **quadratic form**을 이용하여 식 (4)와 같이 정의한다. 해당 값은 경계 수직 방향 가우시안의 분산을 나타내며, 경계가 강한 위치에서 해당 분산 값이 작아지도록 경계 가중치를 반영한 식(5)의 손실함수 L_{edge} 를 정의한다.

$$\Sigma_{2D} = \begin{bmatrix} \sigma_{xx} & \sigma_{xy} \\ \sigma_{xy} & \sigma_{yy} \end{bmatrix} \quad (3)$$

$$\sigma_{\perp} = n^T \Sigma_{2D} n \quad \left(n = \frac{(g_x, -g_y)}{M} = (n_x, n_y) \right)$$

$$\sigma_{\perp} = n_x^2 \sigma_{xx} + 2n_x n_y \sigma_{xy} + n_y^2 \sigma_{yy} \quad (4)$$

$$L_{edge} = \frac{\sum W_{(edge, i)} \sigma_i}{\sum W_{(edge, i)} + \epsilon} \quad (5)$$

λ_{edge} 는 경계 손실의 가중치이며 식(6)의 전체 손실 함수는 기존 RGB 손실 항과 식(5)의 가우시안 공분산 손실 항의 합으로 정의된다.

$$L_{total} = (1 - \lambda_{edge})(1 - \lambda_{SSIM})L_1 + (1 - \lambda_{edge})\lambda_{SSIM}L_{SSIM} + \lambda_{edge}L_{edge} \quad (6)$$

3.2 방법 2: 렌더링 기반 가우시안 크기 제한

방법 2는 가우시안 공분산 손실 항을 추가하지 않고, 렌더링 과정에서 가우시안 크기를 직접 조절하는 방식이다. 각 가우시안에 대해 경계의 강도 e_i 를 기반으로 스케일 비율 r_i 를 식 (7)과 같이 정의하고, 이를 이용하여 조정된 식 (8)의 가우시안 공분산 s'_i 를 적용한 렌더링 결과를 생성한다. 최종 손실은 해당 렌더 결과에 대해 RGB 손실을 계산하는 방식으로 정의된다.

$$r_i = \max(r_{\min}, 1 - e_i(1 - r_{\min})) \quad (7)$$

$$s'_i = r_i s_i \quad (8)$$

4. 실험

4.1 실험환경

본 연구는 Ubuntu 22.04 환경에서 NVIDIA RTX 4090 GPU를 사용하여 학습을 수행하였다. 3DGS 공식 구현을 기반으로 실험하였으며, 동일한 iteration 수(3,000 iter)으로 경계 영역 가우시안 크기 제한 방식에 따른 성능 차이를 비교하였다.

4.2 실험결과

정량적 평가 결과, 전체 손실함수 및 PSNR 기준의 평가에서 제안한 방법 1, 2 모두 기존 방법 대비 개선된 성능을 보였으며, 방법 2는 방법 1과 비교하였을 때 더 우수한 경향을 보인다. <그림 2>는 매 iteration 기준 PSNR과 손실함수 수렴 경향을 나타내며 <그림 3>은 학습 시간 기준 수렴 경향을 나타낸다. 최종 학습 단계(3,000 iteration)에서 측정된 Loss 및 PSNR 값을 정리한 결과는 <표 1>과 같다.




그림 2. 학습 iteration에 따른 PSNR(좌) 및 Loss(우)




그림 3. 학습 시간에 따른 PSNR(좌) 및 Loss(우)

표 1. 최종 iteration에서 Loss 및 PSNR 값

	기존 방식	방법 1	방법 2
Loss	0.01963	0.01822	0.01614
PSNR	31.6	32.14	32.69

정성적 평가를 위해 동일 장면에서 기존 방식과 제안 방법을 비교하였다. <그림 4>는 제안 방법이 기존 방법보다 객체와 배경 간 구조적 분리를 개선함을 보여준다.



그림 4. Baseline(좌), 방법1(중) 방법2(우)의 재구성 결과 비교

4. 결론

본 연구에서는 3차원 가우시안 스플래팅 기반 장면 재구성에서 발생하는 경계 흐림 문제를 해결하기 위해, 경계 정보를 반영한 가우시안 크기 제한 기법을 제안하고 그 효과를 분석하였다.

실험 결과, 제안한 방법은 기존 방식 대비 loss 감소 및 PSNR 향상 측면에서 일관된 성능 개선을 보였으며, 특히 렌더링 기반 가우시안 크기 제한 방식이 더 빠른 초기 수렴과 높은 최종 성능을 달성하는 경향을 확인하였다. 이는 학습 초기 단계에서 가우시안의 과도한 확장을 효과적으로 억제함으로써, 객체 경계 구성을 개선한 결과이다.

향후 연구에서는 다양한 실내외 환경 및 데이터셋에 대한 추가 실험을 통해 제안한 방법의 일반화 가능성을 검증하고, 다양한 장면 조건에서의 재구성 성능을 분석하고자 한다.

참고문헌

- [1] Kerbl B., Kopanas G., Leimkuhler T., & Drettakis G., “3D Gaussian Splatting for Real-Time Radiance Field Rendering” ACM Transactions on Graphics, vol.42, no.4, pp.1-14, Jul. 2023